Chat Transcript: ABSTRACT 翻訳と解説

User

ABSTRACTについて日本語に翻訳し、内容について解説してください。

Aurelle

H-EPMは、過去の成功したツール利用経験を「状況依存の記憶」と「ツール手順の記憶」に分け、マルチターンのエージェントが新しい対話へ転用できるようにする手法です。Abstract

Abstractの日本語訳

ユーザーの意図が対話のなかで徐々に明らかになり、環境も変化していくため、マルチターンのエージェントは継続的に変わる意思決定状況に直面する。過去の経験を再利用することは直感的には有望だが、既存手法には限界がある。すなわち、完全な軌跡は状況に強く依存しすぎて転用しにくく、一方でツール単位の再利用は文脈や環境を無視してしまう。

本論文では、**ハイブリッド・エピソード記憶–手続き記憶戦略（H-EPM）**を提案する。これは、推論時と学習時の両方で、部分的に重なり合う成功経験を適応的に再利用することで、マルチターンのツール利用ポリシーを経験に応じて進化させる手法である。

人間におけるエピソード記憶と手続き記憶の統合に着想を得て、蓄積された軌跡からツールグラフを構築する。このグラフでは、繰り返し現れるツールからツールへの依存関係が手続き的なルーチンを表し、各エッジには、関連する文脈を短く要約したエピソード的情報を付与する。

推論時には、エージェントは、文脈に基づく推論のためのエピソード記憶の想起と、定型的なステップを実行するための手続き記憶の利用を動的に切り替える。さらにH-EPMは推論時だけでなく、マルチターンのエージェントRLにおける中心的課題、すなわち長い軌跡上で探索がうまく働かない問題にも取り組む。過去に成功したツール遷移へ探索を誘導することで、H-EPMは、推論時に領域固有の経験収集へ依存せずに汎化する、より強い方策を学習する。

実験では、H-EPMは複数のマルチターン・ツール利用ベンチマークで強力なベースラインを一貫して上回り、推論時には最大 **50%超** の改善を達成した。またRL方策も改善し、分布外タスクでは最大 **40%超** の性能向上を示した。Abstract

内容の解説

この論文の問題意識は、「過去にうまくいった解決手順を、そのまま丸ごと再利用しても、新しい対話では条件が少し違うため失敗しやすい」という点です。

たとえば携帯通信のサポートエージェントで、過去に「海外で通信できない → データ上限超過 → データを追加」という成功例があったとします。しかし新しいユーザーも海外で通信できない場合、その原因はデータ不足ではなく**ローミング設定がオフ**なのかもしれません。軌跡全体を検索して過去の解法をコピーすると、誤った「データ追加」を選びかねません。

そこでH-EPMは、経験を次の二層に分けます。

- **エピソード記憶**：その時点のユーザー要求、会話履歴、ツールの返答などを圧縮した「現在の状況の要約」。似た状態で何が有効だったかを参照します。
- **手続き記憶**：あるツールの後には次のどのツールが使われやすく、かつ成功・効率的だったかという、ツール列のパターンです。

実装上は、**ノードがツール、エッジが「ツールAの次にツールBを呼んだ」という遷移**の有向グラフになります。エッジの重みには成功頻度だけでなく、成功までに要したステップ数に基づく効率も加えます。各エッジには必要に応じて、その遷移が成功した際の状態要約も複数保存します。Memory Construction

推論時、エージェントはまず「今は詳細な状況整理が必要か」を判断します。

- **必要なら**、会話とツール履歴を要約し、グラフ中の過去の状態要約と類似度を比較します。これはエピソード記憶による、文脈依存の候補提示です。
- **不要なら**、現在のツールから伸びるエッジの重みが高い次ツールを候補にします。これは手続き記憶による、定型処理の高速な誘導です。

いずれの場合も、ツールを一つに強制せず、上位 k 個（論文では主に $k=2$）をLLMへの候補として渡すため、モデル自身の判断余地を残します。Adaptive Retrieval

RLで何が新しいのか

RLでは、長いツール操作列の中で成功報酬にたどり着く確率が低く、ランダム探索だけでは学習が進みにくい問題があります。H-EPMは過去の成功遷移を候補として提示し、成功しそうな方向へ探索を寄せます。

ただし、記憶に従いすぎると新しい解法を見つけられません。そこで著者らは、手続き記憶の候補を確率 p_{skip} で意図的に無視し、探索のランダム性を確保します。成功した新しい軌跡はグラフへオンラインで追加され、記憶自体も訓練に伴って更新されます。H-EPM RL

結果をどう読むべきか

推論時の結果では、H-EPMは全15の主要な比較設定でベースモデルを上回っています。たとえば τ^2-Bench では、Qwen3-8Bが 0.201 から 0.309 へ、相対で **53.7%** 改善しています。Inference Results

RLでは、τ^2-Benchで標準GRPOの 0.178 に対し、H-EPM（$p_{\text{skip}}=1.0$）は 0.223 を達成し、ベースモデル比で **41.1%** の改善です。一方、ToolSandboxでは $p_{\text{skip}}=0.8$ が最良で、ツール列の規則性が強い環境ほど手続き記憶を活かし、状態依存性が高い環境ほどその誘導を強くスキップする、という使い分けを示しています。RL ResultsSkip Rate

要するにH-EPMの核は、**「過去の解決策をコピーする」のではなく、「どの状況で、どのツール遷移が役立ったか」を部品化して再利用すること**です。これにより、定型的な作業では速く、状況が変わった場面では文脈を見ながら柔軟にツールを選べるようにしています。

User

INTRODUCTIONについて日本語に翻訳し、内容について解説してください。

Aurelle

H-EPMの導入部は、マルチターンのツール利用では「現在の指示」だけでは不十分で、会話履歴・過去のツール呼び出し・変化した環境状態を踏まえて次の行動を選ぶ必要がある、と問題を定義しています。Introduction

Introduction の日本語訳

大規模言語モデル（LLM）は、強力な推論能力と意思決定能力を示している。しかし、現実世界の多くのタスクは推論だけでは解決できず、最新情報を得るためのデータベース検索や計算のためのコード実行環境など、外部ツールを必要とする。そのため一般的なエージェント構成では、LLMを中心的な制御器として、計画・記憶・ツール利用のモジュールを組み合わせる。

このようなシステムは、質問が最初から完全に与えられるシングルターン設定では良好に動作する。一方、実用的なアプリケーションは本質的にマルチターンである。ユーザーの意図は対話を通じて段階的に明らかになり、中間のツール呼び出しは環境を変化させる。そのため意思決定の質は、現在のプロンプトだけでなく、対話履歴とそれまでのツール呼び出し列にも依存する。マルチターン設定では環境状態を完全には観測できないため、初期のツール選択は誤りやすい。エージェントには、対話履歴やツール実行によって変化する状態を扱い、新しい証拠が得られるたびに計画を修正する能力が求められる。Introduction

人間は複雑な課題に取り組むとき、繰り返し現れる状況を認識し、過去に成功した経験の一部を選択的に再利用する。神経生物学では、このような再利用はしばしば**エピソード記憶**と**手続き記憶**に区別される。エピソード記憶は、重なり合う出来事を単一のイベントを超えた相互接続的な記憶構造として統合し、柔軟な汎化を可能にする。手続き記憶は、反復練習と過去の行動の強化を通じて、技能を獲得する働きを担う。Introduction

近年の経験ベースLLMエージェントは、これら二種類の記憶をそれぞれ異なる形で取り入れている。過去のタスク解決軌跡を保存・検索する手法は、全軌跡や定義済みサブタスクを想起するという意味で、エピソード記憶に近い。一方、ツールグラフを構築して成功したツール利用パターンを繰り返す手法は、手続き的な規則性を重視している。

しかし、粗い粒度のエピソードと、ツールだけに着目した依存関係のいずれも、マルチターン状況には十分ではない。粗いエピソードは、各軌跡やサブタスクを分割できない単位として扱うため、経験が部分的にしか一致しない場合に再利用・適応しにくい。反対に、ツール間リンクだけを見る方法は、対話履歴や以前のツール呼び出しが次の行動をどのように左右するかを捨象してしまう。IntroductionIntroduction

人間の意思決定が、エピソード記憶と手続き記憶のどちらか一方ではなく、その相互作用から生じるという考えに着想を得て、本論文の枠組みはエピソード的な断片と手続き的なルーチンを結び付ける。具体的には、部分的に重なる軌跡区間を検索すると同時に、繰り返されたツール呼び出し列から安定したツール利用依存関係を抽象化する。これにより、継続的に変化するマルチターンのツール利用場面で、文脈に整合した過去経験の再利用を目指す。Introduction

本論文では、推論時と強化学習（RL）のロールアウト時の両方で、部分的に重なり合う状況において過去の軌跡を適応的に利用し、マルチターン・ツール利用エージェントを経験から進化させる、**Hybrid Episodic–Procedural Memory（H-EPM）**を提案する。

H-EPMは、蓄積したツール利用軌跡からツールグラフを構築する。グラフのエッジは繰り返し現れるツール呼び出しパターンを表すが、ツール間遷移だけではマルチターンの意思決定に必要なタスク固有情報が欠ける。そこで各エッジに、意思決定に関係する対話内容とツール履歴を要約したコンパクトな状態記述子を追加する。これにより、部分的にしか一致しない状況でも、過去経験を検索して適応できる。

推論時には、H-EPMはエピソード記憶と手続き記憶の間で検索方法を適応的に選ぶ。文脈的な想起が必要なときは、関連するエッジ上の状態要約を取り出してツール選択を導く。それ以外では、高信頼度の遷移重みに基づいて定型的な判断を実行する。Introduction

さらにH-EPMは、RLにおいても記憶誘導型の探索機構として使われる。長い軌跡では探索が非効率になりやすいという問題に対し、過去に成功へつながった行動を優先してロールアウトを導くことで、より質の高い軌跡を発見しやすくする。著者らは、このように訓練された方策が、推論時に領域ごとの追加的な経験収集を行わずとも未知タスク・ツールへ汎化できると位置づけています。Contributions

著者らが挙げる貢献は次の3点です。

1. 成功軌跡を、ツールをノード、ツール遷移をエッジとする構造化メモリグラフへ統合し、エッジに「手続き的な遷移パターン」と「エピソード的な状態要約」を持たせるH-EPMを提案した。
2. H-EPMをRLの探索に組み込み、長軌跡での探索の弱さを、成功履歴に基づく行動優先度付けによって緩和した。
3. 複数のベンチマークで、推論時に最大50%超、分布外タスクにおけるRL方策では最大40%超の改善を報告した。
   Contributions

内容の解説

導入部の核心は、既存の経験再利用を両極端だと捉えている点です。

- **軌跡検索型の記憶**：過去の「解決手順全体」を検索する。しかし、新しいケースが過去と完全一致することは少ないため、早い段階で誤った類例に引っ張られやすい。
- **ツールグラフ型の記憶**：ツールA → ツールB のような一般的な順序を利用する。しかし、「今回のユーザーの契約状態・会話内容・直前のツール結果」という状況を見ないので、頻出の手順が正解とは限らない。

H-EPMはその中間を取ります。**ツールのつながり**から「通常なら次に何をするか」を学びつつ、迷う局面では**現在の状態要約**を使って「今回と似た状況では何が成功したか」を参照します。

たとえば通信サポートで顧客情報を取得した直後は、一般的には契約詳細を確認する、という手続き的パターンが有効かもしれません。しかし、ユーザーが「海外にいて、データ上限を超えておらず、ローミングが無効」と判明した状況では、利用量の追加よりローミング有効化が適切です。この「通常の次手」と「今回の状態に固有の次手」の使い分けが、導入部でいうハイブリッド記憶の狙いです。

また、RLへの拡張も重要です。通常の長期タスクでは、偶然に成功軌跡へ到達するまで報酬が得られず、探索が難しくなります。H-EPMは過去の成功経験を**答えの固定**ではなく、探索のための**候補提示**として使います。そのため、ランダム探索だけより効率的に成功へ近づきながら、新しい戦略を試す余地も残す設計になっています。

User

RELATED WORKについて日本語に翻訳し、内容について解説してください。

Aurelle

関連研究では、H-EPMを「**マルチターンのツール利用**」と「**エージェント記憶**」の交点に位置づけ、既存手法が固定軌跡・軌跡単位の再利用・文脈を捨てたツール遷移に偏っていると論じています。Related Work

Related Work の日本語訳

2. 関連研究

2.1 マルチターンのツール利用

マルチターンのツール利用は、エージェントが適切なツールを選択するだけでなく、複数ターンにまたがる対話とツール出力の複雑な相互作用を管理しなければならないため、難しい課題である。

この能力を実現するため、先行研究では教師ありファインチューニング（SFT）と強化学習（RL）の両方が検討されてきた。SFT手法では、グラフ変換を通じた合成マルチターンデータ生成や、シミュレーションされた対話を用いる。RL手法では、対話的なフィードバックを通じてツール利用方策を最適化する。たとえば、MUA-RL と RAGEN は、それぞれユーザーとの相互作用を伴うマルチターンのツール利用と、テキスト環境における自己進化を扱う。また、Group-in-Group Policy Optimization と Tool-Star は、より複雑な推論およびマルチツール環境へRL後学習の枠組みを拡張している。

こうしたアルゴリズム面での進展を補うものとして、DialogTool や ToolSandbox のような近年のベンチマークは、ターンをまたいで状態を維持することの難しさを明らかにし、ツール利用エージェントを体系的に評価する必要性を示している。

それでも、既存のSFTとRLには、過去のマルチターン・ツール利用経験をどう表現し、再利用するかという点で限界がある。SFTは、固定された事前収集済みの軌跡に依存する。一方、RLは長いツール列を、乏しい手掛かりの下で探索することが多く、学習が非効率になりやすい。また、対話文脈が変化したときに適応しにくい。Multi-turn Tool Use

2.2 エージェント記憶

エージェント記憶は、大きく**内部記憶**と**外部記憶**という二つの方向から研究されてきた。

内部記憶は、エージェントの推論モジュールや計画モジュールの内部で生成・維持されるものであり、意思決定を導く中間表現として機能する。これに対して外部記憶は、エージェントの中心的な推論ループの外側に、要約・抽出した情報を保存する。これにより、異なるタスクや時点をまたいで、情報をモジュール的に検索・再利用できる。近年は特に、長い相互作用の中で大量の過去経験を維持し、継続学習と適応的な行動を支えられる点から、外部記憶の重要性が高まっている。Agent Memory

また、記憶の表現形式も多様である。具体的には、生の経験記録、要約されたテキスト、潜在埋め込み表現、グラフ構造に基づく記憶アーキテクチャなどが提案されている。しかし先行手法の多くは、主に**軌跡全体**を単位として扱う。この設計では、経験が一部分だけ重なるマルチターンのツール利用場面において、柔軟性が不足する。

これに対して本論文は、意思決定を**状態レベル**でモデル化する。すなわち、手続き的な類似性と状態の類似性の両方に従って、関連する過去経験を適応的に検索するハイブリッドなエピソード–手続き記憶を用いる。それにより、文脈を踏まえた、効率的なメモリベースの行動誘導を目指す。Agent Memory

内容の解説

この節は、H-EPMの新規性を「既存研究の空白」に対して説明する部分です。主張は次のように整理できます。

研究の流れ	既存の代表的な考え方	著者らが見る限界
マルチターン SFT	合成または収集済みの成功軌跡を学習する	データが固定的で、実行中に変化する文脈や新しい経験を活かしにくい Multi-turn Tool Use
マルチターン RL	環境との対話を通じ、成功報酬からツール利用を学ぶ	長い行動列と疎な手掛かりのため、成功例にたどり着く探索が難しい Contributions
軌跡検索型の記憶	過去の解決例・要約済み軌跡を丸ごと取り出す。たとえば ReasoningBank	新しいタスクと過去の経験が部分的にしか一致しない場合、軌跡全体は粒度が粗すぎる Agent Memory
ツールグラフ型の記憶	ツールA → ツールB のような依存関係を学ぶ。たとえば ToolNet	ツール列の規則性は捉えられても、会話履歴やツール結果による現在の状態を十分に表せない Introduction

重要なのは、著者らが「既存の記憶は役に立たない」と言っているのではなく、**再利用の粒度と条件付けが不十分**だと述べている点です。

軌跡全体の検索は、「以前に似た問題を解いた」という情報を得るには有効です。ただしマルチターン対話では、初期ターンではユーザーの真の問題がまだ判明していないことが多いです。その段階で似た軌跡を丸ごと参照すると、表面的には似ていても原因が異なる過去事例に引っ張られる可能性があります。

一方、ツールグラフは「顧客情報取得の後には契約詳細の取得を行うことが多い」といった定型的な流れを表せます。しかし、ある顧客が海外にいてローミングが無効なのか、データ容量を使い切ったのか、回線が停止しているのかによって、次に選ぶべきツールは変わります。ツール間の頻度だけでは、この違いを扱えません。

H-EPMは、グラフのエッジに**状態要約**も紐付けることで、この両方を扱おうとします。つまり、

- 通常の手順には、ツール遷移の重みを使う
- 現在の事情が重要な局面では、過去の状態要約との類似性を使う

という役割分担です。これが「ハイブリッド・エピソード–手続き記憶」という名前の意味であり、関連研究節から方法論へつながる中心的な発想です。

User

METHODOLOGYについて日本語に翻訳し、内容について解説してください。

Aurelle

H-EPMの方法論は、成功したツール利用経験を「**状態付きツール遷移グラフ**」へ圧縮し、推論では文脈類似性または遷移重み、RLではそれに探索性を加えた仕組みで次のツール候補を提示するものです。Methodology

3. 記憶拡張タスクの定式化

本論文では、マルチターンのツール利用を、部分観測マルコフ決定過程（POMDP）
$(\mathcal{E}, \mathcal{O}, \mathcal{A}, T, \pi_\theta)$
として定式化する。

ここで、$\mathcal{E}$ は対話と環境を含む潜在状態、$\mathcal{A}$ は自然言語の応答とツール呼び出しからなる行動集合、$\mathcal{O}$ はユーザー発話とツールからのフィードバックである。環境の遷移は $T(e_{t+1}\mid e_t,a_{t+1})$ で表される。一方、言語モデル方策 $\pi_\theta(a_{t+1}\mid h_t)$ は、完全な環境状態ではなく、観測可能な相互作用履歴 h_t に基づいて行動する。

時刻 $t+1$ において、エージェントは履歴 h_t を条件に行動 a_{t+1} を選び、観測 o_{t+1} を受け取る。その後、履歴は次のように更新される。

$$h_{t+1} = (h_t, a_{t+1}, o_{t+1})$$

ツール呼び出しは潜在状態を変えうるが、その効果は将来得られる観測を通じて間接的にしか分からない。したがってエージェントは、「現在何が起きているか」を完全には把握できないまま、ツール選択を続けなければならない。Task Formulation

エピソード記憶と手続き記憶

生の会話履歴やツール出力を丸ごと保存すると、経験が個別の状況に過度に最適化され、新しい状況に転用しにくくなります。そこでH-EPMは、生の観測ではなく、**抽象化したツール遷移**を単位に記憶を構築します。

- **エピソード記憶**は、文脈に依存した遷移

  $$(s_t, a_t) \Rightarrow a_{t+1}$$

  を保存します。ここで $s_t=\phi(h_t)$ は、部分観測下で次のツールを選ぶ際に有効な情報を抜き出した、コンパクトな状態要約です。

- **手続き記憶**は、文脈を外したツール遷移

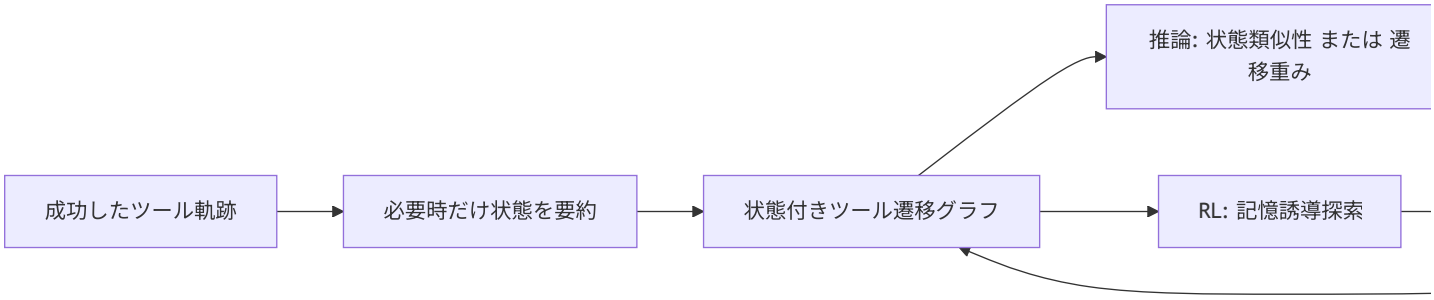
  $$a_t \Rightarrow a_{t+1}$$

  を保存します。これはタスクをまたいで繰り返される、ツールからツールへの実行パターンを表します。Episodic-Procedural Memory

つまり、エピソード記憶は「**この状態なら次に何をすべきか**」、手続き記憶は「**通常、このツールの後には何をするか**」を担います。

4. 方法論

論文の方法は、次の3段階から構成されます。



著者らはまず履歴経験を収集し、次にそれをグラフ型メモリへ変換し、最後にそのメモリを推論とRLのロールアウトに用います。Methodology

4.1 過去経験の収集

マルチターンのツール利用では、必要な情報が長く多様な会話履歴の各所に分散します。H-EPMは履歴 h_t を状態要約 $s_t=\phi(h_t)$ に圧縮し、低レベルな細部を捨てながら、意思決定に必要な情報を残します。

ただし、毎ターン要約するとコストが高くなります。そのため著者らは、エージェント自身が必要なタイミングで呼び出す**状態要約ツール**を導入します。このツールが呼ばれたときに生成される状態要約が、意思決定の補助と記憶保存の両方に使われます。Experience Collection

要約を行うステップでは、エージェントは会話文脈と要約状態を条件として、次の行動を選びます。

$$a_{t+1} \sim \pi_\theta(a_{t+1} \mid h_t, s_t)$$

このとき得られる (s_t,a_t,a_{t+1}) が、エピソード的な経験の基本単位です。著者らは、ベースモデルを訓練データ上でロールアウトしてツール利用軌跡を作り、それを初期メモリにします。訓練データがない場合には、テスト時の軌跡をオンラインで記憶へ取り込むこともできます。RL中は、ロールアウトによって追加の経験を継続収集します。Experience Collection

4.2 H-EPMメモリの構築

H-EPMは、次の状態付きツール遷移グラフを作ります。

$$G = (V, E, W, S)$$

- V：ツール種別に対応するノード
- E：ツールから次ツールへの有向エッジ
- W：ツール遷移の重み、すなわち手続き記憶
- S：エッジに付与された状態要約、すなわちエピソード記憶

たとえば、ツール τ_1 を使った後に要約ツールを呼び、続いて τ_2 を使ったなら、要約された状態 s_t はエッジ (τ_1,τ_2) に保存されます。同じツール遷移でも様々な状況で起こり得るため、各エッジには複数の状態要約を蓄積できます。Memory ConstructionEpisodic Memory

手続き記憶の重み

エッジの重みは、単に「成功例で何回使われたか」だけでなく、「どれだけ短い手順で成功したか」も考慮します。まず未正規化重みを次で定義します。

N(\tau_t,\tau_{t+1}) + c\sum_{k=1}^{N(\tau_t,\tau_{t+1})} \frac{1}{n_k(\tau_t,\tau_{t+1})} w′(τt, τt+1) = N(τt, τt+1) + c k=1∑N(τt,τt+1) nk(τt, τt+1)1

ここで、

- $N(\tau_t,\tau_{t+1})$ は、遷移 $\tau_t\rightarrow\tau_{t+1}$ を含む成功軌跡の数
- $n_k(\tau_t,\tau_{t+1})$ は、該当する k 番目の成功軌跡の総ステップ数

- c は、成功率と効率性の相対的重要度を調整する係数

です。短い軌跡ほど $\frac{1}{n_k}$ が大きくなるため、成功はするものの冗長なツール呼び出しを繰り返す経路を避ける意図があります。著者らはこれを、無害でもタスクに不要なツールを過剰に呼ぶ「tool overuse trap」の緩和として説明しています。Procedural Memory

さらに、現在ツール τ_t から出る候補同士を比べられるよう、重みを正規化します。

$$\frac{w'(\tau_t,\tau_{t+1})}{\sum_{\tau'\in\mathcal{N}(\tau_t)}w'(\tau_t,\tau')}$$

$$w(\tau_t, \tau_{t+1}) = \frac{w'(\tau_t, \tau_{t+1})}{\sum_{\tau' \in \mathcal{N}(\tau_t)} w'(\tau_t, \tau')}$$

$\mathcal{N}(\tau_t)$ は、τ_t の次に利用可能なツールの集合です。これにより、同一ノードから出る遷移重みの合計は 1 となり、次ツールの相対的な重要度として扱えます。Weight Normalization

4.3 H-EPMによる経験駆動の進化

推論時：二種類の検索を動的に切り替える

各ツール呼び出し後、H-EPMは、今呼んだツールに対応するノードをグラフから見つけ、その隣接ノードを次ツールの候補とします。その上で、エージェントは「今、状態要約が必要か」を判断します。Inference

状態要約が必要な場合は、現在の状態を要約し、隣接エッジに保存されている過去の状態要約との類似度を計算します。そして類似度が最も高い上位 k 個のツールを候補として提示します。これは、現在の文脈に近い成功経験を参照する**エピソード記憶**の利用です。

状態要約が不要な場合は、エッジ重みが大きい上位 k 個の隣接ツールを候補にします。これは、過去に頻繁かつ効率的に成功した順序に従う**手続き記憶**の利用です。

重要なのは、候補を一つに固定せず上位 k 件を示す点です。論文では、候補を複数出すことでLLMの柔軟性と汎用性を保てると説明しています。Inference

この方法は、「状態の違いが重要な局面」では文脈的な類例を、「定型的な局面」では統計的に強いツール遷移を使う、という設計です。したがってH-EPMは、経験を固定された正解手順として押し付けるのではなく、次の行動を考えるための候補集合として与えます。Inference Summary

RL時：成功経験で探索を誘導しつつ、探索の余地を残す

RLでは、長いツール列で成功に到達するまで報酬が得られないため、無作為な探索だけでは有効な軌跡を見つけにくくなります。H-EPMは、過去の成功につながったツールを候補として優先提示し、成功軌跡を発見する確率を上げます。H-EPM RL

ただし、既存の経験に従いすぎれば、未知のより良い方策を発見できません。そこでRL中は、手続き記憶が提案する上位 k 個のツール候補を、確率 p_{skip} で**あえて無視**します。この確率的スキップにより、成功経験による誘導と新しい行動の探索を両立させます。H-EPM RL

新たに成功した軌跡はオンラインでグラフへ追加されるため、記憶による候補提示も訓練とともに更新されます。著者らの狙いは、訓練中に外部メモリで探索を助け、最終的には未知のタスク領域に対しても方策そのものがより良いツール選択を行えるようにすることです。Online Evolution

方法のポイント

H-EPMを一言でまとめると、**経験の再利用単位を「軌跡全体」から「状態を伴う次ツール選択」へ細分化した手法**です。

従来の軌跡検索だけでは、表面的には似ていても原因が異なる事例を誤ってコピーしやすくなります。反対に、ツールグラフだけでは「頻出の次ツール」は分かっても、ユーザーの現在地、契約状況、直前の診断結果といった状態を扱いにくいです。

H-EPMはこの二つをエッジ上で結合します。つまり、通常は重み付き遷移で速く進み、判断の分岐が重要なときだけ状態要約との類似度を用いて過去経験を具体的に照合する、という使い分けです。